Contador de objetos em vídeos usando redes neurais convolucionais

Plabiany Rodrigo Acosta

SERVIÇO DE PÓS-GRADUAÇÃO FACOM - UFMS

Data de Depósito:

Assinatura:_____

Contador de objetos em vídeos usando redes neurais convolucionais[1]

Plabiany Rodrigo Acosta

Orientador: *Profº Drº Wesley Nunes Gonçalves*

Dissertação de Mestrado apresentada a Faculdade de Computação - FACOM - UFMS como parte dos requisitos necessários à obtenção do título de Mestre em Ciências de Computação.

MS - Campo Grande
março/2021

[1]FACOM-UFMS

Aos meus pais,
Plácido Acosta e Eusebia P. Villalva,

Aos meus irmãos,
Vanessa Cristina Acosta e Luiz César V. Acosta,

Aos meus sobrinhos,
Luiz Carlos A. Acosta e Larissa A. Acosta.

Agradecimentos

A Deus que reside em mim e que se faz presente em minha respiração no dia-a-dia.

Aos meus pais Plácido Acosta e Eusebia Parede Villalva Acosta, a minha irmã Vanessa Cristina Acosta e ao meu irmão Luiz Cézar Villalva Acosta, por todo o apoio e amor que já recebi e ainda vou receber deles.

Ao Prof. Dr. Wesley Nunes Gonçalves por conduzir e ter idéias que tornaram este trabalho realidade. A Universidade Federal de Mato Grosso do Sul (UFMS).

Abstract

This work presents a method of Neural Network Convolutional (CNN) to count and locate objects in videos through density maps. Each object is represented by a dot only. In this way a 2D Gaussian core is applied at each point to originate the *Ground Truth* of the density map. The method receives a frame from the video in an instant t and the frame in the instant $t-1$. In this way, the time displacement vectors of the objects are estimated, and a refinement of the density map takes place through stages.

A comparison of the number of stages used in the refinement branches is presented, as well as a variation of σ to generate the *Ground Truth* of the objects.

The proposed method was evaluated by the FISHCV155V database, developed by the UCDB INOVISÃO group in partnership with IFMS and Projeto Pacu. In this context, the count of fingerlings, which are newly hatched fish and move thoughtlessly, was analyzed and tested. The architecture obtained $MAE = 0.11$ and *F-measure* $= 98\%$ with $\sigma = 1.1$, using the time displacement vector of the objects. The method demonstrated that the vector of displacement of the objects can assist in the detection and the labeling in the point type can be the way to count excessive amounts of objects in an image.

Resumo

Este trabalho apresenta um método de Rede Neural Convolutional (CNN) para contar e localizar objetos em vídeos através de mapas de densidade. Cada objeto é representado por um ponto apenas. Desta forma um núcleo Gaussiano 2D é aplicado em cada ponto para originar o *Ground Truth* do mapa de densidade. O método recebe um quadro do vídeo em um instante t e o quadro no instante $t-1$. Desta forma Vetores de Deslocamento Temporal dos objetos são estimados, e um refinamento do mapa de densidade acontece através de estágios. São apresentados um comparativo na quantidade de estágios utilizados nos ramos de refinamento, e uma variação de σ para geração do *Ground Truth* dos objetos.

O método proposto foi avaliado pelo banco de dados FISHCV155V, desenvolvido pelo grupo INOVISÃO da UCDB em parceria com o IFMS e a empresa Projeto Pacu. Neste contexto foi analisado e testado a contagem de alevinos, que são peixes recém chocados e se movem irrefletidamente. A arquitetura obteve $MAE = 0.11$ e *F-measure* $= 98\%$ com $\sigma = 1.1$, utilizando o vetor de deslocamento temporal dos objetos. O método demonstrou que o vetor de deslocamento dos objetos pode auxiliar na detecção e a rotulação no tipo ponto pode ser o caminho para contar quantidades excessivas de objetos em uma imagem.

Sumário

Sumário xi
Lista de Figuras xiv
Lista de Tabelas xv

1 Introdução **1**
1.1 Motivação e Lacuna 1
1.2 Aplicação em Contagem de Peixes 3
1.3 Objetivos 4
1.4 Objetivo Geral 4
1.5 Objetivos Específicos 4

2 Revisão Bibliográfica **5**
2.1 Contagem de Peixes 7

3 Método Proposto **9**
3.1 Pré-Processamento das Imagens 10
3.2 Extração do Mapa de Características 11
3.3 Estimativa do Mapa de Densidade 12
3.3.1 Geração do *Ground Truth* do Mapa de Densidade . . . 13
3.4 Estimativa dos Vetores de Deslocamento 14
3.4.1 Geração do *Ground Truth* do Vetor de Deslocamento . 15
3.5 Localização dos Objetos pelo Mapa de Densidade 16

4 Experimentos e Resultados **18**
4.1 Base de Imagens 18
4.1.1 Configuração dos Experimentos 19
4.2 Resultados e Discussão 22
4.2.1 Resultados Quantitativos 22
4.2.2 Resultados Qualitativos 24

5 Conclusões **27**
5.1 Resumo dos Objetivos e Principais Resultados 27
5.2 Limitações 27
5.3 Trabalhos Futuros 28

Referências **36**

Lista de Figuras

1.1 (a) Ilustração da Escada de peixes - [UHE, 2020], (b) sala abaixo do nível d'água [Morais et al., 2005]. 3

3.1 Método proposto recebe o quadro atual I_t e o quadro no instante anterior I_{t-1}. O resultado da concatenação gera um volume de entrada para a VGG-19. A saída desta arquitetura consiste em um mapa de características inicial. Esse mapa alimenta dois ramos que são responsáveis por realizar as predições do mapa de densidade e de vetores de deslocamento. Cada ramo é composto por uma série de E estágios que refinam a suas predições. Ambos ramos compartilham as informações para auxiliar na estimação. 10

3.2 Ilustração do volume de entrada V que consiste na concatenação de um quadro I_t e um quadro anterior I_{t-1}. 11

3.3 Exemplo de um mapa de características predito pela VGG-19. 12

3.4 Exemplo de uma cena e seu mapa de confiança correspondente para diferentes valores de σ. 14

3.5 Ilustração de um vetor para um objeto em quadro. 16

3.6 Exemplos das localizações nos vetores 17

3.7 Ilustração dos vetores estimados pelo segundo ramo apresentado, para cada pixel de cada objeto. 17

3.8 Exemplo do mapa de confiança em três dimensões. 17

4.1 Suporte para Captura das imagens proposta por [Silva Oliveira Junior, 2019] 18

4.2 Imagens retiradas do conjunto de Treinamento [Silva Oliveira Junior, 2019]. 19

4.3 Ilustração do *Heatmap* obtido do *frame* 147 do vídeo número 6, predito pelo modelo treinado por 100 épocas. 24

4.4 Exemplos dos resultados visuais obtidos para o quadro 30 do vídeo 09. A Figura (a) mostra a imagem original, (b) o mapa de densidade, (c) as predições e (d) a estimação dos vetores. 25
4.5 Exemplos dos resultados visuais obtidos para o quadro 270 do vídeo 11. A Figura (a) nos mostra a imagem original, (b) o mapa de densidade, (c) as predições e (d) a estimação dos vetores. 26

5.1 Exemplos dos peixes extremamente próximos que se movem uniformemente. Imagens do vídeo 06, quadro 187 e 188. . 28
5.2 Amostra do próximo banco de imagens a ser testado - vídeo 203. 29

Lista de Tabelas

4.1 Separação dos vídeos e quadros para os Experimentos . . . 19
4.2 Resultados experimentais para a detecção dos alevinos com o método proposto. Comparação entre a variação dos σ e estágios $E = 4$. 23
4.3 Resultados experimentais para a detecção dos alevinos com o método proposto. Comparação entre a variação na quantidade de estágios E usando $\sigma = 1.1$ 23
4.4 Resultados experimentais para a detecção dos alevinos com o método proposto, $E = 4$ estágios, e $\sigma = 1.1$. Comparação do método com e sem os vetores de deslocamento dos peixes, denominado temporal 23

CAPÍTULO

1

Introdução

1.1 Motivação e Lacuna

A aprendizagem profunda (*Deep Learning*) tem se destacado no cenário de Visão Computacional e as Redes Neurais Convolucionais (CNN) [Simonyan and Zisserman, 2014] tem dominado o estado da arte [Jain et al., 1996]. Estudos podem ser encontrados para detecção de objetos [Laguna et al., 2019, Aparna et al., 2018, d. S. Arruda et al., 2018, Li et al., 2018b, Tayara et al., 2018], segmentação de imagens [Zhao et al., 2017, Cao et al., 2016], contagem de objetos [Tayara et al., 2018, Cao et al., 2016, Luiz Antonio Macarini, 2019], entre outros.

Entre as diversas aplicações da Visão Computacional, os métodos de contagem e localização de objetos consistem em detectar e obter a posição de cada objeto individualmente na imagem. Esses métodos tem auxiliado no controle e contagem de pessoas [Gonçalves et al., 2020], carros [Azimi et al., 2018], animais [Sarwar et al., 2018], e até mesmo bactérias [Ferrari et al., 2015]. A maioria dos métodos de contagem são baseados nos mais conhecidos métodos de detecção de objetos (Faster-RCNN [Girshick, 2015], RetinaNet [Lin et al., 2017], YoloV3 [Redmon and Farhadi, 2018]). Esses métodos consideram um retângulo envolvente para cada objeto e podem fornecer tanto a posição (centro do retângulo envolvente) como a contagem (número de retângulos envolventes).

Embora os métodos recentes tenham obtido resultados promissores, três desafios ainda se mantêm. O primeiro desafio é a alta densidade com objetos sobrepostos. Em geral, os métodos de detecção de objetos não

são adequados para cenários densos de objetos [Goldman et al., 2019]. Neste caso, a grande sobreposição dos retângulos envolventes devido a oclusão dificulta o aprendizado dos métodos. Layout Proposal Networks (LPNs) [Hsieh et al., 2017] é um método recente que tem seguido a proposta de detecção de objetos para contagem de carros utilizando camadas da VGG-16. Seu maior problema na contagem está na sobreposição dos retângulos quando carros estão lado a lado na imagem, como em um estacionamento.

Por outro lado, estimar um mapa de densidade para obter a quantidade de objetos tem apresentado resultados promissores [Idrees et al., 2018, Kamijo et al., 2000, Cao et al., 2017] e feito com que estudos tenham esta direção. Um mapa de densidade consiste em estimar a probabilidade de um objeto ocorrer em cada pixel da imagem. Porém a diversidade encontrada nos cenários das imagens (e.g., escala, rotação, etc) dificulta a detecção e contagem por um mapa de densidade. Assim alguns trabalhos buscam encontrar um método eficaz que faça com que o objeto de interesse tenha um destaque nas probabilidades estimadas [Zhang et al., 2015] [Zhang et al., 2017].

O segundo desafio é a necessidade da rotulação detalhada das imagens, o que é difícil de obter em grandes quantidades. A rotulação de um retângulo envolvente para cada objeto na imagem torna-se inviável para cenas muito densas em grandes quantidades de imagens. Por outro lado, a utilização de um único ponto para rotular cada objeto [Hsieh et al., 2017] tem sido grande alvo de estudos. Por exemplo, [Liu et al., 2019a] propõem o método de detecção e contagem de multidões usando pontos na cabeça das pessoas. Os métodos baseados apenas em pontos consideram a informação de contexto ao redor do ponto, pois os objetos compartilham cores, textura e forma. Dessa forma, os métodos tendem a reconhecer mesmo que os limites dos objetos não estejam delimitados durante o aprendizado [Aich and Stavness, 2018].

O terceiro desafio consiste em contar e localizar objetos em uma sequência de imagens. A análise do movimento que objetos realizam nos vídeos podem fornecer informações valiosas que nem sempre são consideradas na contagem de objetos em uma imagem. Nesse contexto, alguns pesquisadores demonstram em seus estudos que rastrear o movimento pode auxiliar na detecção e reconhecimento, assim como distingui-los do fundo ([Ma et al., 2015, Nam and Han, 2016, Danelljan et al., 2015, Wang et al., 2019, Hou et al., 2019, Gonçalves et al., 2020]). Diferente do rastreamento de objetos, o objetivo deste trabalho é considerar as informações do passado para contar e localizar os objetos em um quadro

atual.

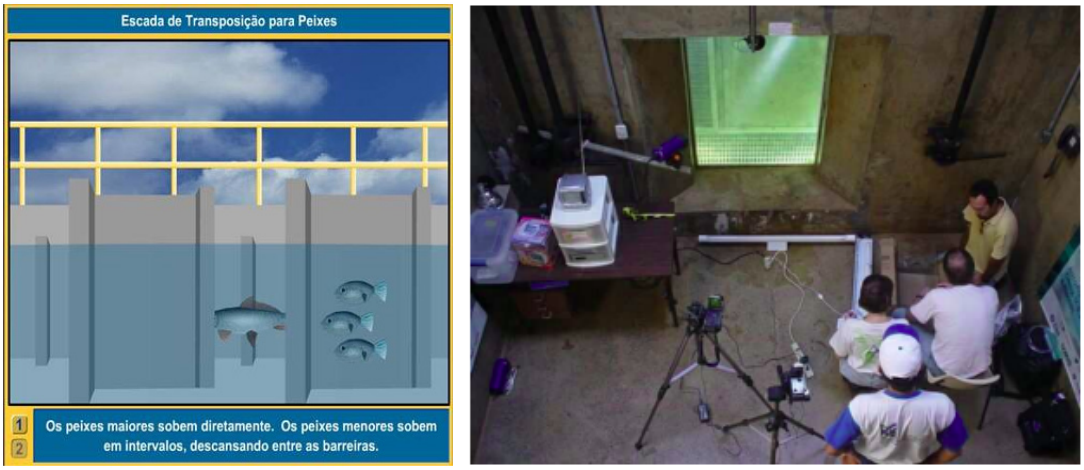
Para contornar os desafios citados acima, este trabalho propõe um método para localizar e contar objetos em vídeos usando redes neurais convolucionais. Dado um quadro de um video e o quadro anterior, o método proposto estima uma mapa de densidade com a probabilidade de ocorrência de um objeto em cada pixel. Dessa forma, a rotulação apenas de pontos é suficiente para o treinamento do método e cenas densas podem ser melhor modeladas. Além disso, o método proposto também estima um mapa de vetores de deslocamento, isto é, vetores que indicam a direção do movimento de cada pixel da imagem. Essa estimativa dos vetores de deslocamento também é usada para predizer o mapa de densidade de um quadro atual. Todas essa informações são concatenadas para estimar a localização e contagem de objetos do quadro atual. Resultados experimentais mostram que a concatenação dessas informações é capaz de melhorar a contagem e localização dos objetos.

1.2 Aplicação em Contagem de Peixes

O método proposto será aplicado na contagem de peixes e alevinos. Na maioria dos casos, a contagem é um trabalho árduo e requer mão de obra humana atenta, além de ser suscetível a erros. Por serem sensíveis, os peixes requerem uma afabilidade no manuseio durante a contagem. Em geral, a contagem acontece por técnicas de barragens [Morais et al., 2005], alguns cultivadores realizam a peneiragem para extrair os peixes da água e, dessa maneira, obtêm-se uma estimativa da quantidade de peixes que residem em uma determinada região [OECD et al., 2018, FAO, 2016].

A escada de peixes é uma das maneiras utilizadas na contagem. Assim os peixes passam por barragens conforme a Figura 1.1 (a). Na usina hidrelétrica de Igarapava do rio Grande [UHE, 2020], pesquisadores construíram salas (Figura 1.1 (b)) abaixo do nível d'água, sendo possível enxergar os peixes conforme eles atravessam. Especialistas na área buscam encontrar técnicas para automatizar a contagem dos peixes que transitam a hidrelétrica.

Os cultivadores precisam ter o controle da quantidade de peixes vivos presentes em seus cativeiros, para que a alimentação seja devidamente proporcional para todos, e se há necessidade do cultivo de novos peixes, ou até mesmo alterações no meio. É notória a necessidade de uma exatidão da quantidade que residem uma região.



(a) (b)

Figura 1.1: (a) Ilustração da Escada de peixes - [UHE, 2020], (b) sala abaixo do nível d'água [Morais et al., 2005].

1.3 Objetivos

1.4 Objetivo Geral

O objetivo deste trabalho é propor um método para contagem de objetos em vídeos utilizando redes neurais convolucionais. Um dos intentos principais está em detectar tais objetos nas imagens levando em consideração a posição espacial no quadro anterior. Assim com a ciência das localizações anteriormente, uma estimativa mais refinada da posição atual pode ser obtida.

1.5 Objetivos Específicos

Tendo o objetivo geral imposto, os seguintes objetivos específicos foram definidos:

1. Estimar a contagem por meio de um mapa de densidade obtido por uma rede neural convolucional;
2. Avaliar a inclusão do quadro anterior na estimativa do quadro atual;
3. Incluir vetores de deslocamento na predição do mapa de densidade;
4. Aplicar o método na contagem de alevinos.

CAPÍTULO

2

Revisão Bibliográfica

As Redes Neurais Convolucionais tem dominado estudos de Aprendizado Profundo, e demonstram resultados promissores quando testadas em problemas reais. Tais redes usam a convolução em pelo menos uma de suas camadas, sendo a convolução uma operação linear [Goodfellow et al., 2016]. Além disso, são capazes de operar com uma ou mais dimensões, portanto é possível utilizar as imagens RGB (3 dimensões) e vídeos (n dimensões) como entradas para treinamento [Arel et al., 2010].

Frente as dificuldades das CNN's, conforme descrito na Seção 1.1. As Redes Neurais Convolucionais ocuparam espaços nos artigos ciêntifícos e são considerados por muitos o estado da arte do Aprendizado Profundo (*Deep Learning*) [Laguna et al., 2019, Aparna et al., 2018, d. S. Arruda et al., 2018, Li et al., 2018b, Tayara et al., 2018, Zhao et al., 2017, Cao et al., 2016, Tayara et al., 2018, Cao et al., 2016, Luiz Antonio Macarini, 2019].

Rotular imagens tornou-se um problema significativo, pois quanto maior a quantidade de amostras, melhor serão os resultados nas predições. Por outro lado, um grande desafio na contagem é a detecção de objetos muitos próximos ou em oclusão, sendo que muitos métodos acabam detectando dois objetos como um [Liu et al., 2019b, Ming Liu et al., 2018, Zhang et al., 2015, Zhang et al., 2017, d. S. Arruda et al., 2018, Kellenberger et al., 201 Rahnemoonfar and Sheppard, 2017, Liu et al., 2018, Luiz Antonio Macarini, 2019, Cheang et al., 2017].

[Cao et al., 2017] demonstrou o início de uma linha de pesquisa que abrange a detecção de pessoas e a estimativa das partes do corpo em tempo real utilizando Redes Neurais Convolucionais. O trabalho propõe o cálculo dos membros de cada pessoa detectada além de uma estima-

tiva do vetor de deslocamento desses membros. Dentre as adversidades encontradas pela técnica de [Cao et al., 2017], uma delas esta em detectar indivíduos que se encontram na imagem, porém com membros em oclusão. [Cao et al., 2017] utiliza a conexão de membros para detectar e assim estimar o corpo humano nas imagens. Desta maneira, cada membro estimado possui um ponto e linhas que ligam tais pontos. Com o intuito de distinguir cada pessoa nas predições, [Cao et al., 2017] dividiram as predições em conjuntos disjuntos. Os autores assumem que todos os pontos preditos pelo modelo são vértices, e as linhas que ligam os membros contemplam as arestas. Assumindo assim um grafo para cada corpo humano predito.

O método foi avaliado com base no banco de dados *MPII-Person Dataset* e *COCO Keypoints Challenge*. Para avaliar os resultados obtidos, [Cao et al., 2017] calcularam a média da precisão das partes do corpo estimados. Assim, o método alcançou uma média de precisão dos membros de 91.2% para o banco de dados *MPII Multi-Person*. O banco de dados COCO obteve uma precisão de 68.2% para detecção de pessoas em larga escala.

Em 2018 [Cao et al., 2018] propôs o novo estado da arte para a estimativa da pose 2D de pessoas presentes nas imagens em tempo real. As poses são construídas com o auxílio de campos de afinidades que estimam os membros do corpo humano, assim como no trabalho de 2017 [Cao et al., 2017]. Além da releitura dos resultados obtidos no banco de dados utilizados no artigo anterior, são apresentados os resultados obtidos pelo metodo para o banco de dados *Foot Keypoint Dataset* e uma estimativa da pose de veículos. O método obteve 77.9% de precisão no conjunto de validação para estimativa da posição humana, e a estimativa da pose de veículos nas imagens em tempo real obteve 70.1% no conjunto de validação.

Em vídeos a detecção e a contagem acontecem em cada quadro do vídeo. Assim os vídeos proporcionam grandes atributos auxiliares na extração das características dos objetos. Uma vez que é possível obter o rastreamento do objeto, a localização, se houve locomoção, se houve alteração no seu formato durante o deslocamento, entre outros . Por outra perspectiva a quantidade excessiva de objetos de interesse nas imagens, fazem com que alguns objetos acabem oclusos, impedindo uma extração de características próxima do ideal, para aquele objeto individualmente.

Contar peixes tem se tornado o foco de pesquisadores pelo mundo, pois obter a quantidade exata de peixes presentes em um criadouro auxilia na produção [FAO, 2016]. A distribuição desigual dos peixes a serem

contados demanda métodos de CNN's que consigam distinguir cada objeto individualmente [Liu et al., 2019b, Simonyan and Zisserman, 2014, Zhang et al., 2015, Ming Liu et al., 2018]. Nesse trabalho, é proposto uma técnica para contar objetos, tendo a ciência indireta das suas localizações em um instante anterior. Na seção a seguir são apresentados métodos para contagem de peixes.

2.1 Contagem de Peixes

[Silva Oliveira Junior, 2019] propôs a contagem e estimativa da massa de alevinos em imagens. O trabalho inclui também um comparativo entre redes convolucionais profundas e algoritmos rasos de regressão. O autor enfatiza que a iluminação presente nas imagens são fundamentais para uma extração relevante das formas de cada objeto. Uma limiarização é aplicada nas imagens de entrada para separar os pixels pertencentes aos peixes do fundo. O *SLIC Superpixels* [Achanta et al., 2012] é aplicado com o intuito de agrupar os pixels que possuem semelhanças, o filtro Kalman [Bianco and Terra, 2009] nas regiões de interesse e por fim a exclusão do fundo. Além disso é levado em consideração pelo método a quantidade de vezes que um objeto foi contado. O melhor resultado foi obtido após o estudo de diversos parâmetros empíricos (e.g., limiar da segmentação, distância entre objetos, etc), tendo uma média dos erros absolutos de $5,99$ unidade de alevinos.

[Silva Oliveira Junior, 2019] também comparou o uso dos seguintes algoritmos rasos de classificação: IBK, com $k = 3$, J48, e SMO. O algoritmo J48 obteve o melhor resultado, atingindo uma acurácia de 58%, revocação 58% e *F-measure* $= 58\%$. O comparativo entre as redes convolucionais deu-se atraves da InceptionV3, ResNet50, VGG16, VGG19 e Xception. Tendo como destaque a ResNet50 [He et al., 2015] que obteve 67% de acurácia no conjunto de testes. O autor destaca que a transferência de aprendizado pode acentuar os resultados, visto que foi realizado um comparativo entre a inicialização da ResNet com e sem os pesos pré-treinados da IMAGENET [Deng et al., 2009]. O trabalhdo de [Silva Oliveira Junior, 2019] mostra que as CNN's se sobresaem quando comparadas a algoritmos rasos.

[Morais et al., 2005] propõe a contagem de peixes e a classificação de espécies. Bem como a avaliação da eficácia da escada de peixes (vide Seção 1.2), também é abordado pela dissertação de mestrado. O método alcançou 80% de acurácia na contagem utilizando o rastreador bayesiano de multiplos objetos (BraMBLe). A contagem dos peixes acontecem em

uma sequência de imagens, através de um rastreamento realizado para cada objeto de interesse. Nesse contexto os objetos são detectados pela estimativa da trajetória realizada por ele na sequência de quadros. Assim quando um objeto sai de cena, e um outro começa a aparecer, uma nova trajetória é construída para este peixe. O esquema de estimar a trajetória do peixe em cena, fez com que o trabalho conseguisse distinguir, por exemplo, dois peixes, que no início do vídeo estão juntos, porém cada um toma um rumo distinto no decorrer do vídeo.

[Tseng and Kuo, 2020] apresentou a combinação da ResNet101 [He et al., 2015], e a FPN (*feature pyramid network* [Lin et al., 2016]) para contar e detectar peixes. O resultado obtido foi de 77.3% de precisão e 93.8% de revocação, na contagem de peixes. [Sung et al., 2017] aplicou a Rede Neural Convolucional YOLO (*You Only Look Once*) na detecção de peixes no fundo do mar. A YOLO alcançou 93% de acurácia, sendo que os autores afirmam que a CNN não obteve uma boa acurácia em lugares com pouca iluminação.

[Lainez and Gonzales, 2019] apresentou uma técnica com 4 passos principais para a contagem de alevinos: redimensionamento das imagens de entrada para 400×400 pixels, converter as imagens para escala de cinza, fatiar cada imagem em 16 ou 36 segmentos, encontrar o valor de limiar e por fim detectar e contar alevinos, utilizando uma CNN. A CNN aplicada para detectar e contar os alevinos é uma proposta dos autores [Lainez and Gonzales, 2019], e a rede consiste basicamente em duas camadas convolucionais seguidas de *Pooling* e no fim uma camada totalmente conectada. A rede possui duas camadas convolucionais, seguidas de *Pooling* e por último uma camada totalmente conectada. A detecção e contagem obteve uma precisão de 99.63% e 99.17%.

Os trabalhos citados comprovam a eficácia das CNN's quando testadas em várias situações de contagem no mundo real. Os trabalhos que realizam a contagem em vídeos quase sempre utiliza informações de várias cenas para auxiliar na detecção. A técnica de utilizar cenas anteriores para melhorar os resultados, será avaliada neste trabalho, pois as localizações anteriores de cada objeto são levadas em consideração.

CAPÍTULO

3

Método Proposto

O método proposto recebe um quadro I_t no instante t e o quadro no instante anterior I_{t-1}. A saída gerada pela arquitetura consiste em um mapa de densidade 2D indicando a localização de cada alevino presente no quadro e a estimativa dos vetores de deslocamento para cada alevino.

Vide as dificuldades das CNN's em detectar objetos que se movem rapidamente em vídeos (Seção 1.1). Este método recebe informações das cenas anteriores a fim de passar para os ramos de estimativa, a localização e formato do objeto em diversas ocasiões.

A ordenação metodológica pode ser descrita em quatro passos principais conforme a Figura 3.1. Inicialmente, as imagens passam por um pré-processamento (passo 1) para construção do volume de entrada (V). Após isso um mapa de características é obtido para V usando uma CNN (e.g., VGG19[Simonyan and Zisserman, 2015]) (passo 2). O mapa de características é dado como entrada para dois ramos que estimam o mapa de densidade (passo 3) e os vetores de deslocamento (passo 4). As seções abaixo descrevem as etapas em detalhes.

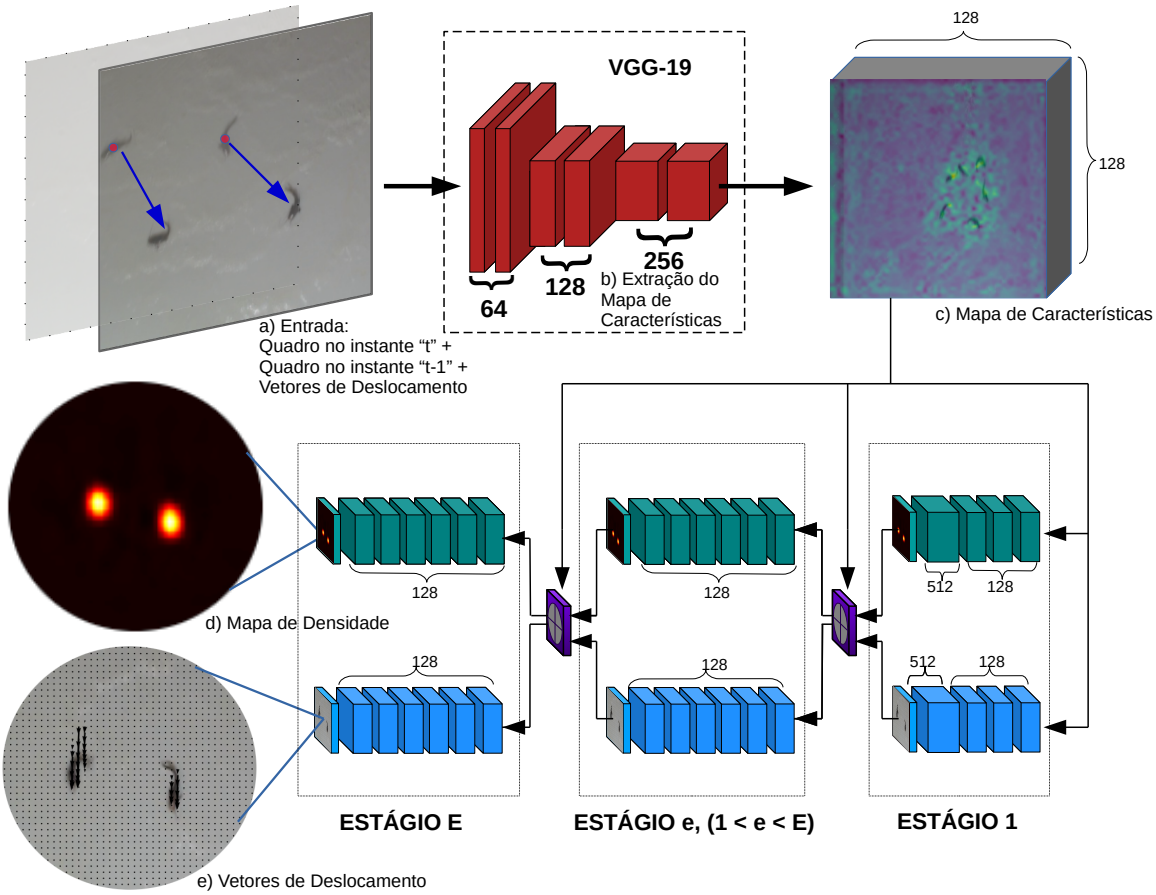


Figura 3.1: Método proposto recebe o quadro atual I_t e o quadro no instante anterior I_{t-1}. O resultado da concatenação gera um volume de entrada para a VGG-19. A saída desta arquitetura consiste em um mapa de características inicial. Esse mapa alimenta dois ramos que são responsáveis por realizar as predições do mapa de densidade e de vetores de deslocamento. Cada ramo é composto por uma série de E estágios que refinam a suas predições. Ambos ramos compartilham as informações para auxiliar na estimação.

3.1 Pré-Processamento das Imagens

Dada uma imagem I_t no instante t com $w \times h$ pixels, em que w é a largura e h é a altura da imagem, o primeiro pré-processamento consiste em redimensionar todas as imagens para um tamanho fixo de $n \times n$ pixels.

O método recebe um volume de entrada V, resultante da concatenação de um quadro I_t no instante t e o quadro anterior I_{t-1}, $V = (I_t, I_{t-1})$, conforme a figura 3.2. Sendo I_t uma imagem RGB com $512 \times 512 \times 3$ pixels e I_{t-1} uma outra imagem do instante anterior com a mesma dimensão, temos que V possui dimensão $512 \times 512 \times 6$.

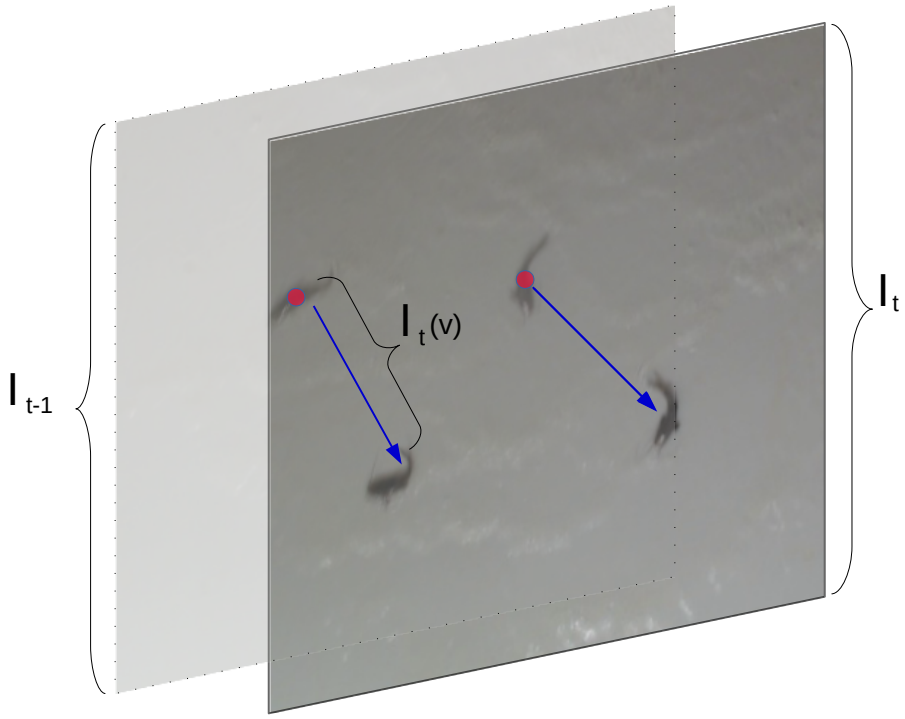


Figura 3.2: Ilustração do volume de entrada V que consiste na concatenação de um quadro I_t e um quadro anterior I_{t-1}.

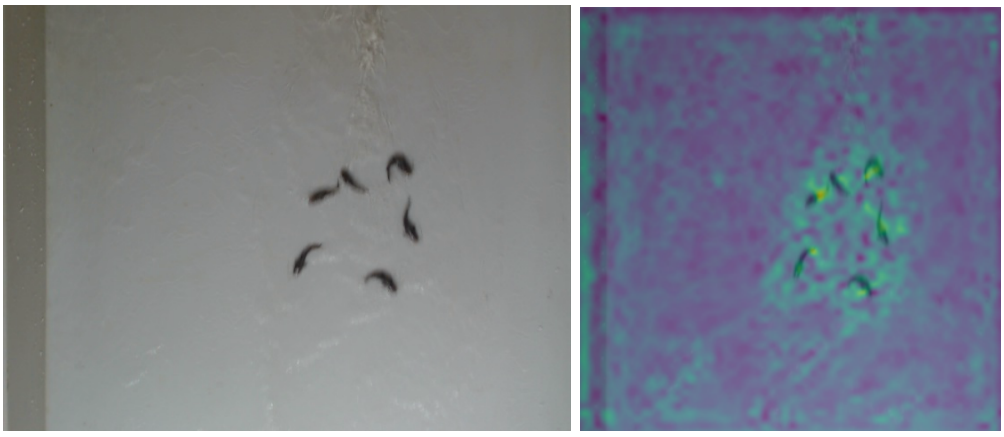
3.2 Extração do Mapa de Características

Nessa etapa, o volume de entrada $V = (I_t, I_{t-1})$ é submetido a uma CNN VGGNet [Simonyan and Zisserman, 2015] para obtenção de um mapa de características. Esse mapa tem como objetivo extrair informações relevantes da imagem de entrada. A VGGNet mostrou que a profundidade da CNN é um componente importante para o bom desempenho. Os autores da VGG19 apresentaram seis arquiteturas: duas com 11, uma com 13, duas com 16, e uma com 19 camadas [Simonyan and Zisserman, 2015]. A CNN de 19 camadas convolucionais e totalmente conectadas é uma das melhores arquiteturas dentre as propostas pelos autores, sendo uma arquitetura homogênea pois só executa convoluções com campo receptivo 3×3 e subamostragens 2×2. A Figura 3.1 ilustra as camadas da arquitetura VGG19 aplicadas no método proposto.

A entrada da VGG19 consiste em duas imagens RGB com dimensão $512 \times 512 \times 6$, que passa por um pré-processamento inicial no qual é realizada a subtração da cor média de todos os pixels da imagem. Esse processo é repetido para todas as imagens que serão usadas para o treinamento da CNN. As imagens passam pelas camadas convolucionais que aplicam um filtro de tamanho 3×3, por ser o menor tamanho capaz de aprender características das quatro direções e do centro durante o pro-

cesso de convolução. O passo de deslocamento do filtro convolucional (*stride*) é de 1 pixel. O preenchimento com zeros ao redor da imagem é realizado de forma a preservar a dimensão da imagem após a convolução, ou seja, para os filtros de tamanho 3×3 é usado um preenchimento com zeros de tamanho 1. Além disso, a função de ativação não-linear ReLu é aplicada após cada camada convolucional.

A amostragem descendente (*Pooling*) é feita através de duas camadas de subamostragens distribuídas no corpo da CNN. Assim, nem todas camadas convolucionais são seguidas de camadas de subamostragens. Os autores usam uma camada de subamostragem máxima com campo receptivo 2×2 e deslocamento de 2 pixels. Ao final da primeira etapa, o volume de entrada V é representado por um mapa de características F extraído pelas camadas da VGGNet. Na Figura 3.3 temos a imagem original e o mapa de características obtido através da VGG19.



(a) Imagem Original (b) mapa de características

Figura 3.3: Exemplo de um mapa de características predito pela VGG-19.

3.3 Estimativa do Mapa de Densidade

Dado o mapa de característica F, o primeiro ramo do método proposto estima o mapa de densidade com o objetivo de detectar cada objeto. Essa predição é realizada por E estágios. No primeiro estágio (Figura 3.1 (c)), uma série de camadas convolucionais Ω geram o mapa de densidade $\hat{C}^1 = \Omega(F)$. Ω é uma sequência de cinco camadas convolucionais: três camadas com 128 filtros de tamanho 3×3, uma camada com 512 filtros de tamanho 1×1 e uma camada com um único filtro que corresponde

ao mapa de densidade. O segundo ramo responsável pela estimativa dos vetores de deslocamento $\hat{D}^1$ estão detalhadas na Seção 3.4. Por enquanto precisamos saber que as estimativas também são utilizados para servir de entrada dos estágios seguintes.

Os estágios refinam as predições do mapa de densidade em etapas sucessivas por E estágios, i.e., $e \in \{1, \ldots, E\}$. Nos estágios subsequentes ao primeiro (Figura 3.1), o mapa de características F, a estimativa de densidade do estágio anterior $\hat{C}_t^{e-1}$ e as estimativas dos vetores de deslocamento $\hat{D}^{e-1}$ (Seção 3.4) são concatenados e usados para produzir um mapa de densidade refinado $\hat{C}^e = \Psi(F, \hat{C}^{e-1}, \hat{D}^{e-1})$. A concatenação de diferentes informações auxilia no apendizado do método e espera-se que a informação de deslocamento ajude na detecção dos objetos no quadro atual. No refinamento, Ψ é uma sequência de sete camadas convolucionais: cinco camadas com 128 filtros de tamanho 7×7, uma camada com 128 filtros de tamanho 1×1 e uma camada com um único filtro que corresponde ao mapa de densidade.

Para treinar os estágios, a função de perda (Equação 3.1) é aplicada no final de cada estágio comparando a predição do método $\hat{C}^e$ com as anotações realizadas por um especialista C. Esta supervisão intermediária aborda o problema do gradiente de desaparecimento, como mostrado em [Cao et al., 2017].

$$f^e = \sum_p \parallel C(p) - \hat{C}^e(p) \parallel_2^2, \tag{3.1}$$

onde C é o *ground truth* do mapa de densidade do quadro t gerado de acordo com a Seção 3.3.1. Por fim, a função de perda global é dada pela soma de todos os estágios:

$$f = \sum_{e=1}^{E} f^e \tag{3.2}$$

3.3.1 Geração do Ground Truth do Mapa de Densidade

Dadas as posições $L = [\{l^1, l^2, \ldots, l^K\} \mid \forall\, l^k = (x_k, y_k)]$ de K objetos em um quadro I_t, o mapa de confiança (*ground truth*) C é obtido colocando-se um núcleo Gaussiano 2D em cada posição dos objetos. Para obter C, um mapa de confiança C^k é primeiro calculado para cada objeto $k \in [1, K]$. O valor de cada posição $p \in \Re^2$ em C^k é definido como:

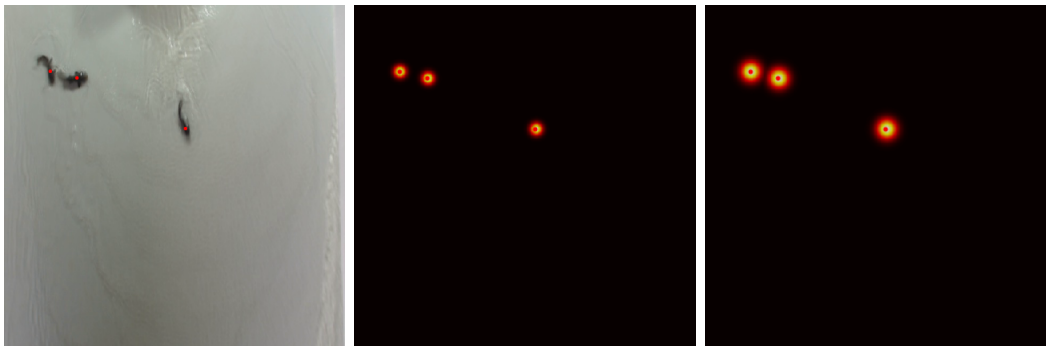
$$C^k(p) = \exp\left(-\frac{\|p - l^k\|_2^2}{\sigma^2}\right), \tag{3.3}$$

onde σ corresponde a largura dos picos que representa cada objeto.

O mapa de confiança C é obtido pela agregação dos mapas individuais via operador máximo:

$$C(p) = \max_{1<k<K} C^k(p). \tag{3.4}$$

A Figura 3.4 ilustra o mapa de confiança para uma imagem e dois valores de σ. A primeira imagem mostra as posições dos objetos em pontos vermelhos que foram anotados pelo especialista. As próximas duas imagens apresentam os mapas de confiança para $\sigma = 1.5$ e 2.5, respectivamente. Por fim, usamos o mapa de confiança *ground truth* para treinar a abordagem proposta.



(a) Imagem Original (b) $\sigma = 1.5$ (c) $\sigma = 2.5$

Figura 3.4: Exemplo de uma cena e seu mapa de confiança correspondente para diferentes valores de σ.

3.4 Estimativa dos Vetores de Deslocamento

O segundo ramo do método proposto (Figura 3.1 (d)) possui camadas convolucionais com os mesmos parâmetros do primeiro ramo. Entretanto, a última camada de cada estágio produz a estimativa do deslocamento em x e y. O primeiro estágio possui uma série de camadas convolucionais Ω que geram os vetores de deslocamento $\hat{D}^1 = \Omega(F)$ para o quadro t.

Nos demais estágios, o mapa de características F, o mapa de densidade $\hat{C}^{e-1}$ (Seção 3.3) e a estimativa do estágio anterior $\hat{D}^{e-1}$, são concatenados e usados para produzir os vetores de deslocamento refinado $\hat{D}^e = \Psi(F, \hat{C}^{e-1}, \hat{D}^{e-1})$. Ψ é uma sequência de sete camadas convolucionais conforme o primeiro ramo.

Para treinar os estágios dos vetores de deslocamento, a função de perda (Equação 3.5) é aplicada no final de cada estágio.

$$f^e = \sum_p \parallel D(p) - \hat{D}^e(p) \parallel_2^2, \tag{3.5}$$

onde D é o *ground truth* dos vetores de deslocamento do quadro t gerado de acordo com a Seção 3.4.1. Por fim, a função de perda global é dada por:

$$f = \sum_{e=1}^{E} f^e \tag{3.6}$$

3.4.1 Geração do Ground Truth do Vetor de Deslocamento

Considere l_t^k como a posição de um objeto k no quadro t e l_{t-1}^k sua posição no quadro anterior. O vetor de deslocamento do objeto k é um vetor que aponta de l_{t-1}^k até l_t^k, conforme a Figura 3.5. Para a construção dos vetores de deslocamento densos, isto é, para cada pixel da imagem, um conjunto de pixels ρ ao redor do vetor de deslocamento principal é obtido. Todos os pixels cuja a distância para o vetor de deslocamento for menor ou igual a um é considerado nesse conjunto. Cada pixel $p \in \rho$ armazena um vetor unitário v com a mesma direção do deslocamento de $t-1$ para t do objeto k, sendo $v = (l_{t-1}^k - l_t^k)/\|(l_{t-1}^k - l_t^k)\|_2$. Os pixels restantes recebe um vetor nulo. O mesmo procedimento é realizada para todos os objetos k no quadro atual e um mapa denso de vetor de deslocamento D é obtido para treinamento do método proposto.

A Figura 3.6 mostra os alevinos na cor branca, os pontos na cor azul apontam a posição dos alevinos no quadro atual I_t e os pontos na cor vermelho mostram as localizações no quadro anterior I_{t-1}. Nas imagens da Figura 3.7 temos a ilustração dos vetores estimados, sendo estimado um vetor para cada pixel que representa o objeto de interesse.

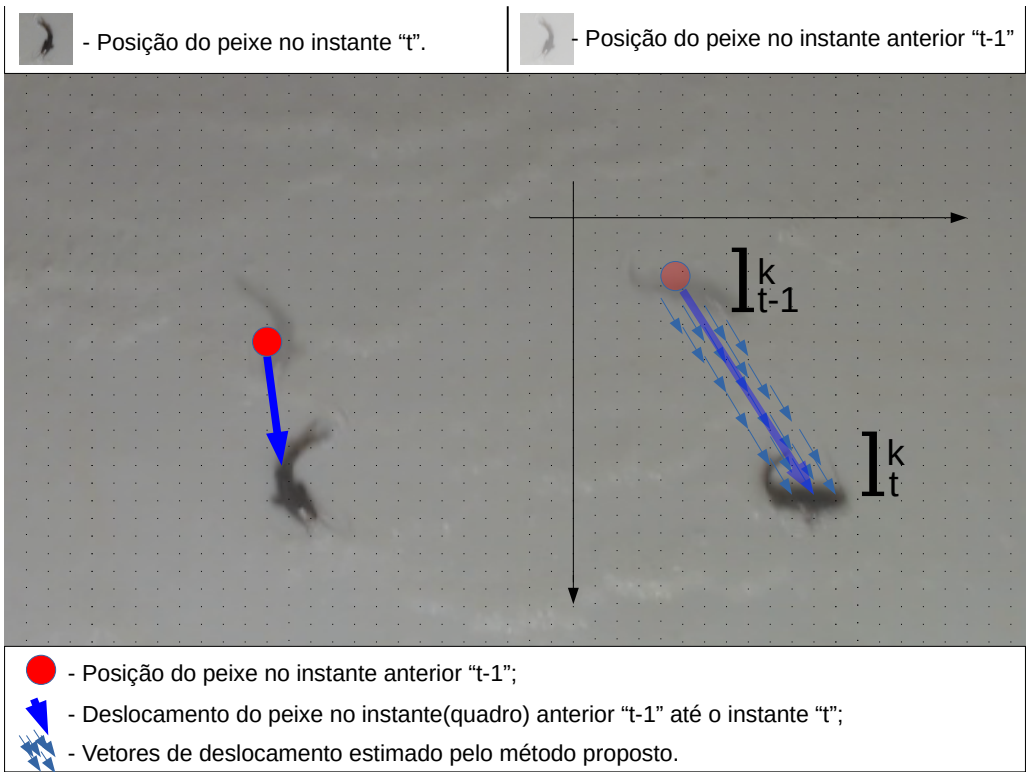
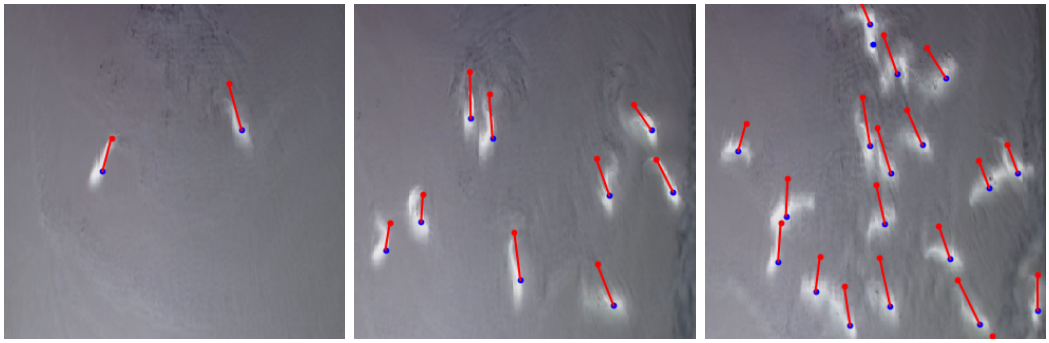


Figura 3.5: Ilustração de um vetor para um objeto em quadro.

3.5 Localização dos Objetos pelo Mapa de Densidade

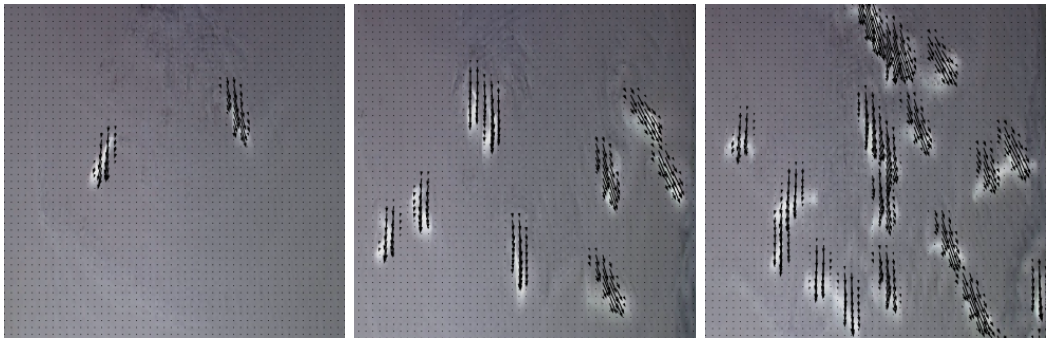
A localização dos objetos é obtida dos picos (máximo local) do mapa de densidade predito do último estágio $\hat{C^E}$. Um local $p = (x_p, y_p)$ é um máximo local se $\hat{C^E}(p) > \hat{C^E}(v)$ para todos os vizinhos v. Consideramos a vizinhança de 4 pixels para todos os locais $p = (x_p, y_p)$, ou seja, $v = (x_p \pm 1, y_p)$ ou $(x_p, y_p \pm 1)$.

Para evitar ruído, os picos precisam ser separados por pelo menos δ pixels. Isso impede que dois alevinos sejam detectados muito próximos uns dos outros. Além disso, um pico deve ter uma confiança maior que um limite τ. Após experiências preliminares, usamos $\delta = 10$ e $\tau = 0.2$. A Figura 3.8 mostra um exemplo tridimensional do mapa de confiança, onde a largura e a altura são as dimensões da imagem e os picos azuis representam as regiões com máxima confiança local.



(a) (b) (c)

Figura 3.6: Exemplos das localizações nos vetores



(a) (b) (c)

Figura 3.7: Ilustração dos vetores estimados pelo segundo ramo apresentado, para cada pixel de cada objeto.

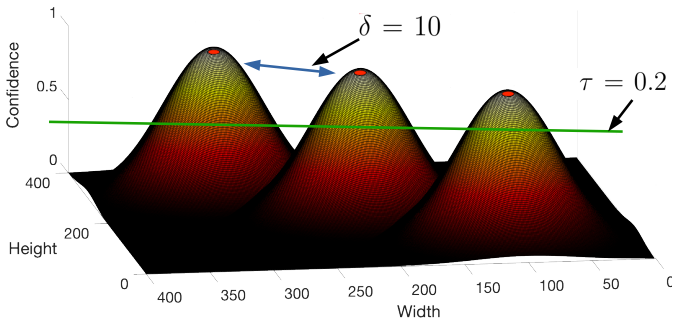


Figura 3.8: Exemplo do mapa de confiança em três dimensões.

CAPÍTULO

4

Experimentos e Resultados

4.1 Base de Imagens

Os vídeos aplicados nos experimentos foram obtidos a partir do banco FISHCV155V, desenvolvido pelo grupo INOVISÃO da UCDB, em parceria com o IFMS e a empresa Projeto Pacu [Silva Oliveira Junior, 2019]. Os vídeos foram gravados entre os meses de julho e setembro de 2018 com uma câmera com resolução full hd (1920×1080 pixels) e uma taxa de captura de 30 quadros por segundo. A câmera foi acoplada a uma estrutura criada pelos autores com uma inclinação aproximada de 12 graus, por onde os alevinos deslizam com o auxílio de água. A Figura 4.1 mostra a estrutura construída para a obtenção dos vídeos.

Dentre os vídeos do banco de dados FISHCV155V, foram selecionados

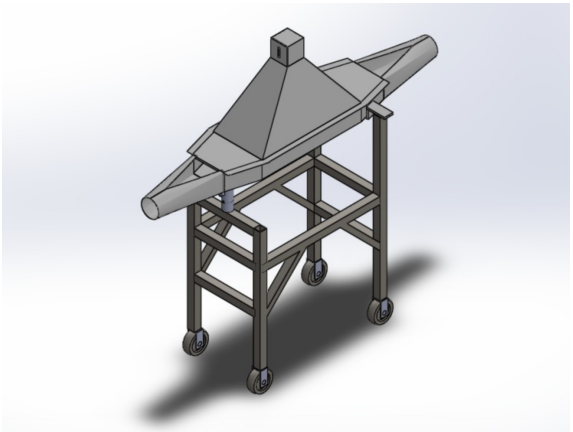


Figura 4.1: Suporte para Captura das imagens proposta por [Silva Oliveira Junior, 2019]

aleatoriamente 15 para compor o banco de dados do experimentos. O conjunto de treinamento é composto por 7 vídeos, sendo que o menor (tempo) vídeo contém 180 quadros e o maior 750 quadros; O conjunto de testes possui 4 vídeos, entre 240 e 300 quadros. O conjunto de validação possui 4 vídeos, sendo o menor 210 quadros e o maior 390. Na Figura 4.2 temos alguns exemplos das imagens utilizadas nos experimentos. Na Tabela 4.1 a quantidade exata do conjunto é apresentado.

Banco de Dados	**Quantidades**	
	Vídeos	**Quadros**
Treinamento	7	2730
Teste	4	1080
Validação	4	1230

Tabela 4.1: Separação dos vídeos e quadros para os Experimentos

.



Figura 4.2: Imagens retiradas do conjunto de Treinamento [Silva Oliveira Junior, 2019].

4.1.1 Configuração dos Experimentos

Para avaliar a abordagem proposta, as amostras foram divididas aleatoriamente em conjuntos de treinamento contendo 7 vídeos, validação 4 vídeos e teste 4 vídeos. Para o treinamento, o otimizador Gradiente Descendente Estocástico foi usado com um momento de 0,9. O ajuste de hiper parâmetros na taxa de aprendizado e no número de épocas foi realizado usando o conjunto de validação para reduzir o risco de *overfitting*. Após experimentos preliminares para ajuste de hiper parâmetro, a taxa de aprendizado foi de 0,01 e o número de épocas foi de 100.

Todos os experimentos foram executados na GPU (Unidade de Processamento Gráfico) NVIDIA GeForce GTX TITAN X (5120 Compute Unified Device Architecture - núcleos CUDA e memória gráfica de 12 GB), sistema operacional Ubuntu 18.04. A implementação proposta faz o uso da API (Interface de Programação de Aplicativos) de alto nível denominada Keras [Chollet et al., 2015], escrita na linguagem de programação

Python. As rotinas desta interface são executadas através da biblioteca de código aberto TensorFlow [Abadi et al., 2015].

Transfer Learning

Em vez de treinar a abordagem proposta do zero, os pesos da primeira parte foram inicializados com pesos pré-treinados no ImageNet em um conceito conhecido como *transfer learning*. Esse método proporciona uma certa rapidez no treinamento de CNNs, evitando treinamentos do zero (aleatoriamente). Quanto maior e mais geral o conjunto de treinamento do modelo pré-treinado, maior será a eficiência da transferência de aprendizado ([Abadi et al., 2015, Li et al., 2018a]). A ImageNet é um conjunto que contém 1,2 milhões de imagens com 1000 categorias [Russakovsky et al., 2014]. Por ser um conjunto extenso existem vários modelos treinados nas arquiteturas mais conhecidas da literatura.

Métricas de Classificação

Para avaliar o método foram utilizados as métricas de regressão que medem a concordância entre o número de objetos anotados e os preditos. A métrica de erro absoluto médio (*mean absolute error* - MAE) é calculada conforme a Equação 4.1.

$$MAE = \frac{\sum_{t=1}^{T} |\hat{x}_t - x_t|}{T} \tag{4.1}$$

onde $\hat{x}_t$ representa o número de objetos preditos pelo método e x_t o número de objetos anotados em um conjunto de T quadros do conjunto de testes [Wang and Lu, 2018].

Para avaliar a localização dos objetos preditos em uma imagem, nós usamos a precisão, revocação e métrica F1 ou medida-f. Para calcular essas métricas, é necessário determinar o número de verdadeiros positivos (VP), falsos positivos (FP) e falsos negativos (FN). Um verdadeiro positivo é obtido se um ponto predito pelo método proposto está dentro de um raio máximo r de um ponto rotulado (neste trabalho usamos raio máximo igual a 5 pixels). Um falso positivo é obtido quando o método proposto prediz um objeto que não foi rotulado, isto é, nenhum ponto a uma distância r. Por fim, um falso negativo é obtido quando nenhum ponto é predito a uma distância r de um ponto rotulado.

A Precisão é definida conforme a Equação 4.2, isto é, o número de verdadeiros positivos (VP) sobre o número de verdadeiros positivos mais o número de falsos positivos (FP).

$$P = \frac{VP}{VP + FP} \tag{4.2}$$

Revocação é definido com o número de verdadeiros positivos (VP) sobre o número de verdadeiros positivos mais o número de falsos negativos (FN), conforme a Equação 4.3.

$$R = \frac{VP}{VP + FN} \tag{4.3}$$

Para obter uma exatidão dos acertos, usamos a F1 que produz uma média harmônica da precisão e da revocação. A revocação está focada nos pontos que deverão ser classificados como positivos, enquanto que a precisão calcula os pontos positivos que foram preditos como positivos pelo modelo. A função alcança seu melhor valor em 1 e pior em 0 [Sasaki, 2007]:

$$F1 = 2 \cdot \frac{P \cdot R}{P + R} \tag{4.4}$$

4.2 Resultados e Discussão

Nas subseções abaixo são demonstrados os resultados com detalhes condizente com os experimentos e as técnicas que geraram resultados relevantes.

4.2.1 Resultados Quantitativos

As Tabelas 4.2, 4.3 e 4.4 mostram os resultados obtidos nos experimentos do método proposto após treinamentos de 100 épocas. As tabelas apresentam a comparação dos resultados obtidos para diferentes variações de sigmas, número de estágios e o uso dos vetores de deslocamento como informação auxiliar na detecção dos objetos. Para uma avaliação adequada em desafios com vários peixes em um único quadro, nós reportamos as métricas em diversos cenários apresentados em cada coluna nas tabelas. O primeiro considera o cálculo das métricas em todos os quadros do conjunto de teste (primeira coluna das tabelas). Os demais cenários consideram somente quadros que contenham uma quantidade i de peixes, e $i \geq 1, 2, 4, 6, 8, 10$. Por exemplo, a coluna $i \geq 10$ indica que somente foram considerados os quadros com 10 ou mais peixes no cálculo das métricas. Portanto, o desafio imposto nesse cenário é muito maior quando comparado com quadros com poucos peixes.

Conforme descrito da Seção 3.3.1, a parâmetro σ controla a largura dos picos que representa cada objeto no mapa de densidade. Isto posto, a Tabela 4.2 apresenta os resultados dos experimentos realizados para uma variação do valor de σ. Dessa forma, $\sigma = 0.7$ gera picos com um raio menor, enquanto $\sigma = 1.3$ gera picos com um raio maior. O número de estágio nesses experimentos foi fixado em $E = 4$.

Analisando os resultados apresentados na Tabela 4.2, podemos notar que o melhor resultado foi obtido para $\sigma = 1.1$, alcançando $F1 = 98\%$ e $MAE = 0.11$ de acertos e erros contabilizando todos os quadros. Esse resultado é extremamente relevante pois o método proposta erra em média apenas 0.11 peixes por quadro. Como esperado, quando a quantidade de peixes considerados por quadro aumenta, os valores de acertos diminuem. Entretanto, mesmo quando somente quadros com 10 ou mais peixes são considerados, foram obtidos resultados relevantes com $F1 = 90\%$ e MAE = 1.71. Para as variadas quantidade de peixes $\geq 1, 2, 4, 6, 8, 10$ o melhor σ obteve uma média de $F1 = 93\%$ de acertos.

Outro parâmetro relevante do método proposto é a quantidade de estágios E. Conforme a Seção 3, os estágios podem ser concatenados para refinar as predições do mapa de densidade. Na Tabela 4.3 temos os re-

Sigma	Todos		$i \geq 1$		$i \geq 2$		$i \geq 4$		$i \geq 6$		$i \geq 8$		$i \geq 10$	
	MAE	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**
0.7	0.343	0.933	0.561	0.893	0.823	0.877	1.372	0.849	2.958	0.765	3.133	0.788	3.071	0.816
0.8	0.217	0.960	0.353	0.938	0.523	0.926	0.843	0.915	2.041	0.852	2.433	0.842	2.642	0.843
0.9	0.156	0.975	0.254	0.960	0.377	0.952	0.612	0.945	1.750	0.878	2.200	0.858	2.428	0.857
1	0.138	0.978	0.226	0.965	0.331	0.959	0.524	0.954	1.583	0.891	2.000	0.872	2.0	0.885
1.1	**0.116**	**0.981**	**0.189**	**0.971**	**0.274**	**0.967**	**0.431**	**0.963**	**1.354**	**0.909**	**1.766**	**0.888**	**1.714**	**0.905**
1.2	0.125	0.980	0.204	0.969	0.295	0.965	0.460	0.961	1.416	0.904	1.800	0.886	1.857	0.895
1.3	0.126	0.982	0.206	0.972	0.302	0.965	0.480	0.959	1.479	0.900	1.933	0.877	2.000	0.886

Tabela 4.2: Resultados experimentais para a detecção dos alevinos com o método proposto. Comparação entre a variação dos σ e estágios $E = 4$.

.

sultados para uma variação de E em cada ramo da arquitetura proposta. Os valores mostram que ao utilizar $E = 4$ estágios temos um resultado maior do que quando E assume outros valores. As métricas para $E = 4$ estágios alcançaram o melhor resultado dentre os apresentados, tendo 98% de acertos para a contabilização de todos os peixes. Os resultados também mostram que usando $E < 4$ apresenta valores excelentes para a contagem de todos os peixes, mas quando a contagem acontece por meio da quantidade de peixes em cada quadro, o método mostrou uma queda na eficiência de contagem. Isso mostra que os estágios ajudam a refinar o mapa para a contagem dos objetos.

Estágios	Todos		$i \geq 1$		$i \geq 2$		$i \geq 4$		$i \geq 6$		$i \geq 8$		$i \geq 10$	
	MAE	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**
1	0.227	0.955	0.368	0.931	0.483	0.928	0.598	0.939	1.333	0.902	1.700	0.880	1.785	0.899
2	0.140	0.976	0.227	0.964	0.333	0.959	0.524	0.952	1.520	0.890	1.900	0.871	2.071	0.881
4	**0.116**	**0.981**	**0.189**	**0.971**	**0.274**	**0.967**	**0.431**	**0.963**	**1.354**	**0.909**	**1.766**	**0.888**	**1.714**	**0.905**
6	0.122	0.980	0.198	0.969	0.288	0.965	0.451	0.961	1.395	0.905	1.800	0.886	1.714	0.904

Tabela 4.3: Resultados experimentais para a detecção dos alevinos com o método proposto. Comparação entre a variação na quantidade de estágios E usando $\sigma = 1.1$

.

Após o modelo proposto apresentar o melhor resultado utilizando $E = 4$ estágios e $\sigma = 1.1$, os resultados da Tabela 4.4 mostra a comparação do uso ou não do ramo que estima os vetores de deslocamento temporal conforme a Seção 3.1. Apesar dos valores similares, o resultado se destaca quando o ramo que estima os vetores de deslocamento é utilizado. Isso corrobora que a inclusão de informação mesmo que indireta da localização do objeto anteriormente melhora os resultados.

Temporal	Todos		$i \geq 1$		$i \geq 2$		$i \geq 4$		$i \geq 6$		$i \geq 8$		$i \geq 10$	
	MAE	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**	**MAE**	**F1**
Sim	**0.116**	**0.981**	**0.189**	**0.971**	**0.274**	**0.967**	**0.431**	**0.963**	**1.354**	**0.909**	**1.766**	**0.888**	**1.714**	**0.905**
Não	0.138	0.978	0.227	0.964	0.328	0.959	0.534	0.949	1.500	0.897	1.866	0.882	1.928	0.891

Tabela 4.4: Resultados experimentais para a detecção dos alevinos com o método proposto, $E = 4$ estágios, e $\sigma = 1.1$. Comparação do método com e sem os vetores de deslocamento dos peixes, denominado temporal

.

4.2.2 Resultados Qualitativos

A Figura 4.4 ilustra como o mapa de densidade representa a presença de um alevino na imagem. Cada pico apontado no *Heatmap* consiste na presença de um alevino.

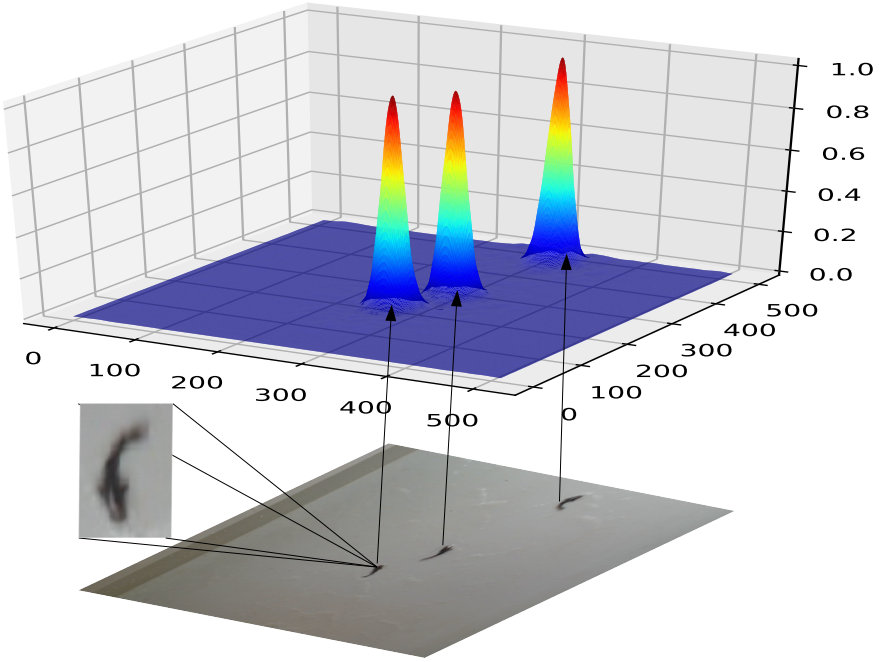
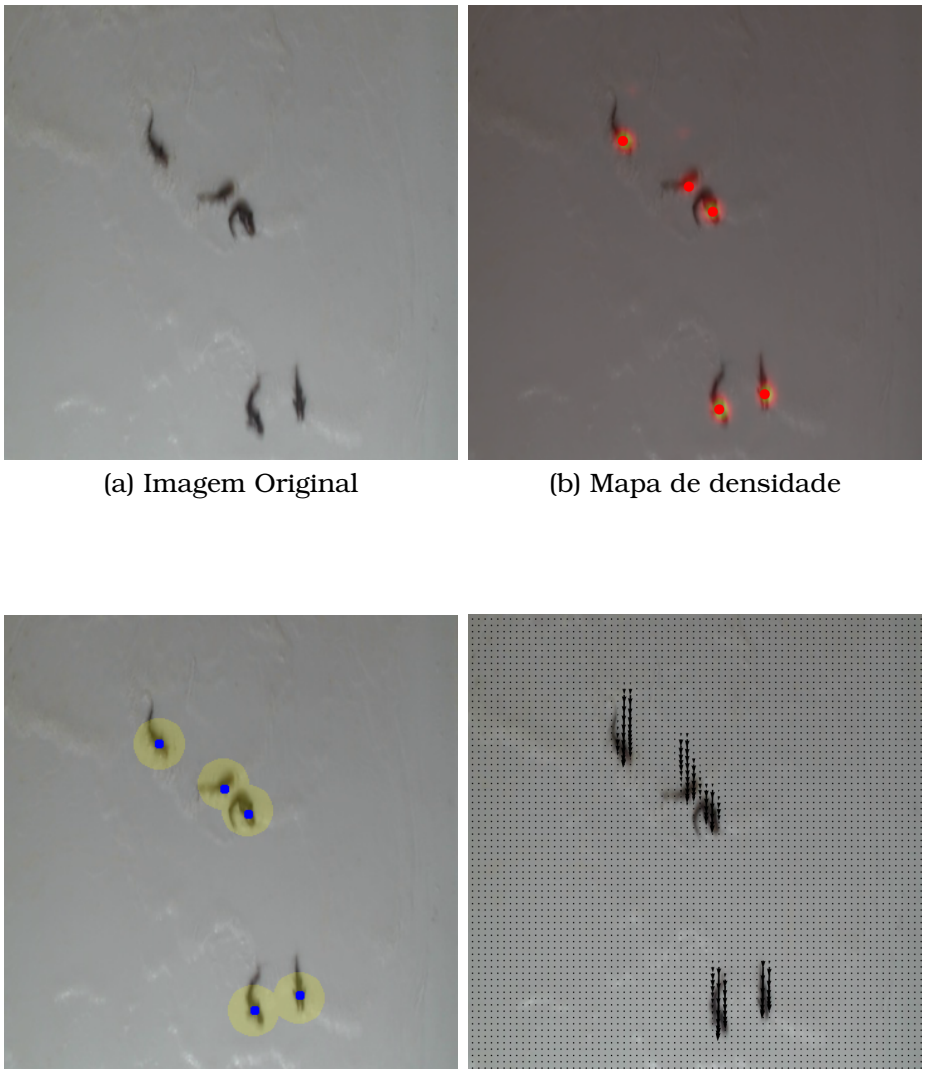


Figura 4.3: Ilustração do *Heatmap* obtido do *frame* 147 do vídeo número 6, predito pelo modelo treinado por 100 épocas.

Podemos observar nas imagens da Figura 4.4 o quadro original, o mapa de densidade, as detecções e a avaliação da métrica *F1* e a estimativa dos vetores de deslocamento. Todos os peixes presente no quadro foram detectados e os vetores foram estimatidos para as posições anteriores. Neste caso em específico temos dois peixes próximos que foram detectados e contabilizados individualmente.

Haja vista a Seção 4.2.1 os quadros onde a quantidade de alevinos é ≤ 6, os alevinos são facilmente detectados. Quando a presença de peixes é ≥ 6 a CNN detecta os alevinos em sua grande maioria, mas existe aqueles que por algum motivo tiveram uma deformação em sua forma na imagem. O movimento realizado pelo peixe diz muito sobre a sua forma.

Um dos problemas da abordagem proposta esta na detecção correta do alevino quando parte do seu corpo está oclusa na imagem. Isso acontece, pois uma das características da CNN é buscar identificar o alevino considerando uma distribuição de probabilidade de um alevino estar em um pixel. Dessa forma, para que a CNN consiga predizer um alevino, boa



(a) Imagem Original

(b) Mapa de densidade

(c) Predições

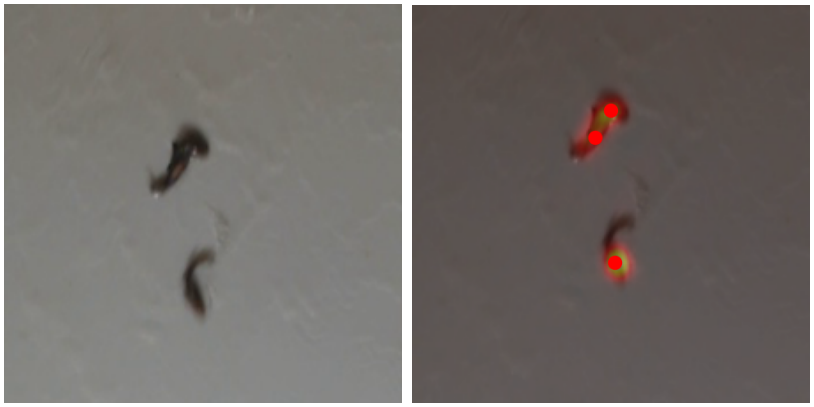
(d) Estimativa dos Vetores de Deslocamento

Figura 4.4: Exemplos dos resultados visuais obtidos para o quadro 30 do vídeo 09. A Figura (a) mostra a imagem original, (b) o mapa de densidade, (c) as predições e (d) a estimação dos vetores.

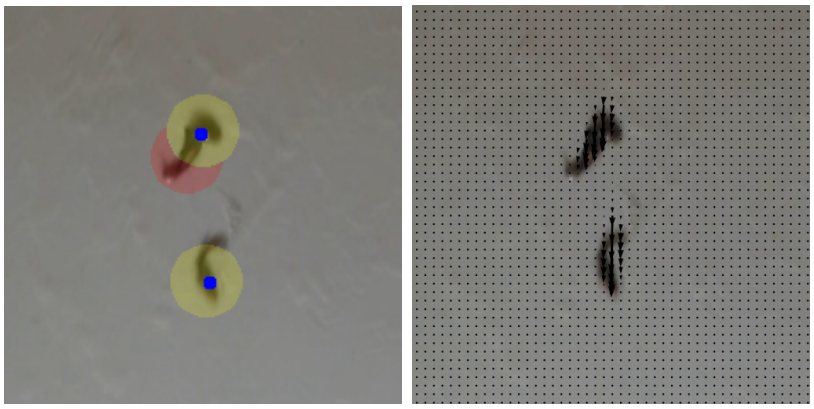
parte do formato dele deve aparecer na imagem, para que uma resposta alta a esse padrão seja encontrada.

Nas imagens presentes na Figura 4.5 temos um quadro onde existem três alevinos, porém os dois mais próximos, foram contabilizados apenas como um. Um alevino encontra-se extremamente próximo ao outro, impossibilitando de serem distinguidos a olho nu. Em alguns quadros na sequência temos que os dois peixes chegam a se separar, porém existem casos em que dois alevinos se movem uniformemente. Essa aproximação confundi a estimativa de vetores, que estima um número de vetores deslocamento diferente.

Por outro lado, outro grande desafio é detectar corretamente o formato do alevino na imagem. Podemos observar que quase sempre por conta da



(a) Imagem Original (b) *Ground Truth*



(c) Predições (d) Estimativa dos Vetores de Deslocamento

Figura 4.5: Exemplos dos resultados visuais obtidos para o quadro 270 do vídeo 11. A Figura (a) nos mostra a imagem original, (b) o mapa de densidade, (c) as predições e (d) a estimação dos vetores.

colisão entre eles os alevinos formam um padrão disforme ao usual. Apesar desses desafios, o método proposto é capaz de detectar corretamente a grande maioria dos alevinos.

CAPÍTULO

5

Conclusões

Neste capítulo são apresentadas as conclusões deste trabalho. Na Seção 5.1 é realizado um paralelo entre os objetivos desta tese e os resultados obtidos. Na Seção 5.2 são discutidas algumas limitações das soluções propostas e na Seção 5.3 são apresentadas algumas direções de trabalhos futuros.

5.1 Resumo dos Objetivos e Principais Resultados

O objetivo principal deste trabalho foi apresentar a capacidade de aplicar camadas convolucionais para contar objetos em vídeos, considerando as posições dos mesmos no quadro anterior. Assim são estimados um mapa de densidade e a estimativa de deslocamento de alevino.

O melhor resultado obtido alcançou 98% de acertos avaliados pela métrica F1, o que nos mostra que a técnica proposta se ajusta positivamente ao conjunto de dados. A métrica de erro MAE afirma que os equívocos cometidos pela rede em camadas é próximos a 0. O objetivo de refinar o mapa de características utilizando os vetor de deslocamento foi alcançado visto que os melhores resultados se mostraram a partir do processamento das posições que precedem o quadro atual.

5.2 Limitações

Os alevinos estão em constante movimento nos vídeos, porém existem alguns peixes, geralmente dois(ou até mais) que se juntam e mantém um

certo movimento uniforme confundindo a CNN, fazendo-a detectar apenas um peixe naquela posição na imagem. Como o deslocamento dos dois são análogos nos quadros anteriores I_{t-1}, no quadro atual I_t processado não há possibilidade de se distinguir um do outro. O pico apontado pela CNN para estes peixes extremamente próximos é único e como a detecção é obtida através deles, a CNN detecta estes peixes como um. Na imagem 5.1 temos um exemplo de dois peixes que se movimentam igualmente sem indicar uma desaproximação.



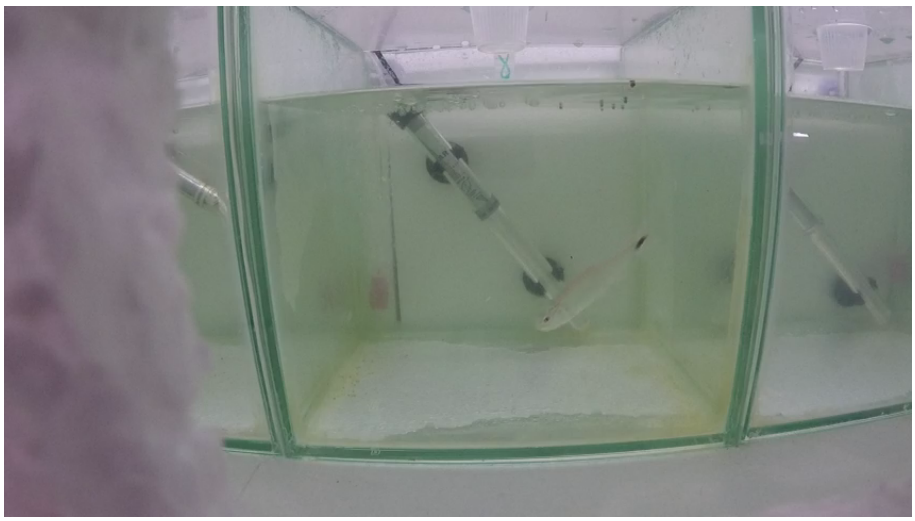
(a) quadro 187 (b) quadro 188

Figura 5.1: Exemplos dos peixes extremamente próximos que se movem uniformemente. Imagens do vídeo 06, quadro 187 e 188.

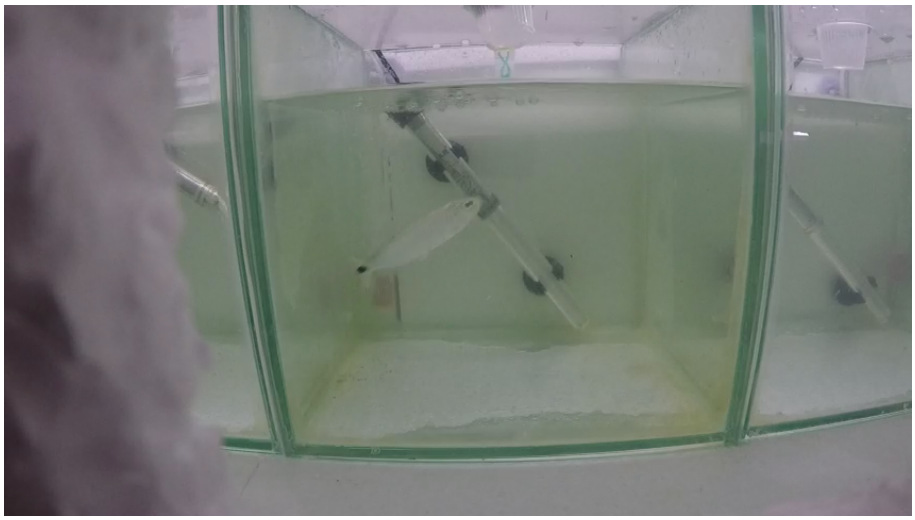
5.3 Trabalhos Futuros

O fato de ocorrer peixes muito próximos nos faz entender que a técnica deverá abordar este tipo de situação. No qual serão testados técnicas para distinguir tais alevinos de maneira com que cada um seja detectado e somado a contagem final.

O método proposto será reavaliado em outro banco de imagens, para averiguar o potencial da técnica em detectar peixes em várias situações do mundo real. Nas imagens da Figura 5.2 temos amostras do banco a ser utilizado em novos experimentos.



(a) quadro 4810



(b) quadro 6253

Figura 5.2: Amostra do próximo banco de imagens a ser testado - vídeo 203. .

Referências Bibliográficas

[UHE, 2020] (2020). UHE Igarapavaconsórcio da usina hidrelétrica de igarapava. http://www.uhe-igarapava.com.br/zpublisher/secoes/home.asp. Accessed: 2020-01-01. Citado nas páginas xiii e 3.

[Abadi et al., 2015] Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G. S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., Levenberg, J., Mané, D., Monga, R., Moore, S., Murray, D., Olah, C., Schuster, M., Shlens, J., Steiner, B., Sutskever, I., Talwar, K., Tucker, P., Vanhoucke, V., Vasudevan, V., Viégas, F., Vinyals, O., Warden, P., Wattenberg, M., Wicke, M., Yu, Y., e Zheng, X. (2015). TensorFlow: Large-scale machine learning on heterogeneous systems. Software available from tensorflow.org. Citado nas páginas 19 e 20.

[Achanta et al., 2012] Achanta, R., Shaji, A., Smith, K., Lucchi, A., Fua, P., e Susstrunk, S. (2012). Slic superpixels compared to state-of-the-art superpixel methods. *IEEE transactions on pattern analysis and machine intelligence*, 34. Citado na página 7.

[Aich and Stavness, 2018] Aich, S. e Stavness, I. (2018). Improving object counting with heatmap regulation. Citado na página 2.

[Aparna et al., 2018] Aparna, P., MP, H., Sounder, H., K, N., P V, V., e Hebbar, R. (2018). Cnn based technique for automatic tree counting using very high resolution data. In *2018 International Conference on Design Innovations for 3Cs Compute Communicate Control (ICDI3C)*, páginas 127–129. Citado nas páginas 1 e 5.

[Arel et al., 2010] Arel, I., Rose, D. C., e Karnowski, T. P. (2010). Deep machine learning - a new frontier in artificial intelligence research [re-

search frontier]. *IEEE Computational Intelligence Magazine*, 5(4):13–18. Citado na página 5.

[Azimi et al., 2018] Azimi, S., Vig, E., Kurz, F., e Reinartz, P. (2018). Segment-and-count: Vehicle counting in aerial imagery using atrous convolutional neural networks. *ISPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, XLII-1:19–23. Citado na página 1.

[Bianco and Terra, 2009] Bianco, A. F. e Terra, M. H. (2009). Filtros de kalman robustos para sistemas dinâmicos singulares em tempo discreto. Master's thesis, Universidade de São Paulo. Citado na página 7.

[Cao et al., 2018] Cao, Z., Hidalgo, G., Simon, T., Wei, S., e Sheikh, Y. (2018). Openpose: Realtime multi-person 2d pose estimation using part affinity fields. *CoRR*, abs/1812.08008. Citado na página 6.

[Cao et al., 2016] Cao, Z., Simon, T., Wei, S., e Sheikh, Y. (2016). Realtime multi-person 2d pose estimation using part affinity fields. *CoRR*, abs/1611.08050. Citado nas páginas 1 e 5.

[Cao et al., 2017] Cao, Z., Simon, T., Wei, S.-E., e Sheikh, Y. (2017). Realtime multi-person 2d pose estimation using part affinity fields. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 1302–1310. Citado nas páginas 2, 5, 6, e 13.

[Cheang et al., 2017] Cheang, E. K., Cheang, T. K., e Tay, Y. H. (2017). Using convolutional neural networks to count palm trees in satellite images. *CoRR*, abs/1701.06462. Citado na página 5.

[Chollet et al., 2015] Chollet, F. et al. (2015). Keras. https://keras.io. Citado na página 19.

[d. S. Arruda et al., 2018] d. S. Arruda, M., Spadon, G., Rodrigues, J. F., Gonçalves, W. N., e Machado, B. B. (2018). Recognition of endangered pantanal animal species using deep learning methods. In *2018 International Joint Conference on Neural Networks (IJCNN)*, páginas 1–8. Citado nas páginas 1 e 5.

[Danelljan et al., 2015] Danelljan, M., Hager, G., Shahbaz Khan, F., e Felsberg, M. (2015). Convolutional features for correlation filter based visual tracking. In *The IEEE International Conference on Computer Vision (ICCV) Workshops*. Citado na página 2.

[Deng et al., 2009] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., e Fei-Fei, L. (2009). ImageNet: A Large-Scale Hierarchical Image Database. In *CVPR09*. Citado na página 7.

[FAO, 2016] FAO, editor (2016). *FAO*. FAO, Rome, Italy. Citado nas páginas 3 e 6.

[Ferrari et al., 2015] Ferrari, A., Lombardi, S., e Signoroni, A. (2015). Bacterial colony counting by convolutional neural networks. In *2015 37th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, páginas 7458–7461. Citado na página 1.

[Girshick, 2015] Girshick, R. B. (2015). Fast R-CNN. *CoRR*, abs/1504.08083. Citado na página 1.

[Goldman et al., 2019] Goldman, E., Herzig, R., Eisenschtat, A., Goldberger, J., e Hassner, T. (2019). Precise detection in densely packed scenes. In *IEEE Conf. on Computer Vision and Pattern Recognition*, páginas 5227–5236. Citado na página 1.

[Gonçalves et al., 2020] Gonçalves, P., Lourenço, B., Santos, S., Barlogis, R., e Misson, A. (2020). Computer vision intelligent approaches to extract human pose and its activity from image sequences. *Electronics*, 9:159. Citado nas páginas 1 e 2.

[Goodfellow et al., 2016] Goodfellow, I., Bengio, Y., e Courville, A. (2016). *Deep Learning*. MIT Press. http://www.deeplearningbook.org. Citado na página 5.

[He et al., 2015] He, K., Zhang, X., Ren, S., e Sun, J. (2015). Deep residual learning for image recognition. *CoRR*, abs/1512.03385. Citado na página 7.

[Hou et al., 2019] Hou, B., Li, J., Zhang, X., Wang, S., e Jiao, L. (2019). Object detection and trcacking based on convolutional neural networks for high-resolution optical remote sensing video. In *IGARSS 2019 - 2019 IEEE International Geoscience and Remote Sensing Symposium*, páginas 5433–5436. Citado na página 2.

[Hsieh et al., 2017] Hsieh, M., Lin, Y., e Hsu, W. H. (2017). Drone-based object counting by spatially regularized regional proposal network. In *2017 IEEE International Conference on Computer Vision (ICCV)*, páginas 4165–4173. Citado nas páginas 1 e 2.

[Idrees et al., 2018] Idrees, H., Tayyab, M., Athrey, K., Zhang, D., Al-Máadeed, S., Rajpoot, N. M., e Shah, M. (2018). Composition loss for counting, density map estimation and localization in dense crowds. *CoRR*, abs/1808.01050. Citado na página 2.

[Jain et al., 1996] Jain, A. K., Jianchang Mao, e Mohiuddin, K. M. (1996). Artificial neural networks: a tutorial. *Computer*, 29(3):31–44. Citado na página 1.

[Kamijo et al., 2000] Kamijo, S., Matsushita, Y., Ikeuchi, K., e Sakauchi, M. (2000). Traffic monitoring and accident detection at intersections. *IEEE Transactions on Intelligent Transportation Systems*, 1(2):108–118. Citado na página 2.

[Kellenberger et al., 2017] Kellenberger, B., Volpi, M., e Tuia, D. (2017). Fast animal detection in uav images using convolutional neural networks. In *2017 IEEE International Geoscience and Remote Sensing Symposium (IGARSS)*, páginas 866–869. Citado na página 5.

[Laguna et al., 2019] Laguna, A. B., Riba, E., Ponsa, D., e Mikolajczyk, K. (2019). Key.net: Keypoint detection by handcrafted and learned CNN filters. *CoRR*, abs/1904.00889. Citado nas páginas 1 e 5.

[Lainez and Gonzales, 2019] Lainez, S. M. D. e Gonzales, D. B. (2019). Automated fingerlings counting using convolutional neural network. In *2019 IEEE 4th International Conference on Computer and Communication Systems (ICCCS)*, páginas 67–72. Citado na página 8.

[Li et al., 2018a] Li, F., Johnson, J., e Yeung, S. (Spring 2018a). Cs231n: Convolutional neural networks for visual recognition. http://cs231n.github.io/assets/cnn/depthcol. Citado na página 20.

[Li et al., 2018b] Li, W., Dong, R., Fu, H., e Yu, L. (2018b). Large-scale oil palm tree detection from high-resolution satellite images using two-stage convolutional neural networks. *Remote Sensing*, 11(1). Citado nas páginas 1 e 5.

[Lin et al., 2017] Lin, T., Goyal, P., Girshick, R. B., He, K., e Dollár, P. (2017). Focal loss for dense object detection. *CoRR*, abs/1708.02002. Citado na página 1.

[Lin et al., 2016] Lin, T.-Y., Dollár, P., Girshick, R. B., He, K., Hariharan, B., e Belongie, S. J. (2016). Feature pyramid networks for object detection. *CoRR*, abs/1612.03144. Citado na página 8.

[Liu et al., 2018] Liu, X., Chen, S. W., Aditya, S., Sivakumar, N., Dcunha, S., Qu, C., Taylor, C. J., Das, J., e Kumar, V. (2018). Robust fruit counting: Combining deep learning, tracking, and structure from motion. *CoRR*, abs/1804.00307. Citado na página 5.

[Liu et al., 2019a] Liu, Y., Shi, M., Zhao, Q., e Wang, X. (2019a). Point in, box out: Beyond counting persons in crowds. *CoRR*, abs/1904.01333. Citado na página 2.

[Liu et al., 2019b] Liu, Z., Chen, Y., Chen, B., Zhu, L., Wu, D., e Shen, G. (2019b). Crowd counting method based on convolutional neural network with global density feature. *IEEE Access*, PP:1–1. Citado nas páginas 5 e 6.

[Luiz Antonio Macarini, 2019] Luiz Antonio Macarini, A. C. S. (2019). Using convolutional neural network to detect and count individuals on eucalyptus plantation. *X Computer on the Beach*, páginas 1–1. Citado nas páginas 1 e 5.

[Ma et al., 2015] Ma, C., Huang, J.-B., Yang, X., e Yang, M.-H. (2015). Hierarchical convolutional features for visual tracking. In *The IEEE International Conference on Computer Vision (ICCV)*. Citado na página 2.

[Ming Liu et al., 2018] Ming Liu, Jue Jiang, Zhenqei Guo, Zenan Wang, e Yang Liu (2018). Crowd counting with fully convolutional neural network. In *2018 25th IEEE International Conference on Image Processing (ICIP)*, páginas 953–957. Citado nas páginas 5 e 6.

[Morais et al., 2005] Morais, E. F., Campos, M. F. M., Machado, A. M. C., e Carceroni, R. L. (2005). Rastreamento e contagem de peixes utilizando filtro preditivo. Citado nas páginas xiii, 3, e 7.

[Nam and Han, 2016] Nam, H. e Han, B. (2016). Learning multi-domain convolutional neural networks for visual tracking. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Citado na página 2.

[OECD et al., 2018] OECD, Food, e of the United Nations, A. O. (2018). Ecd-fao agricultural outlook (edition 2018). Citado na página 3.

[Rahnemoonfar and Sheppard, 2017] Rahnemoonfar, M. e Sheppard, C. (2017). Deep count: Fruit counting based on deep simulated learning. *Sensors*, 17(4). Citado na página 5.

[Redmon and Farhadi, 2018] Redmon, J. e Farhadi, A. (2018). Yolov3: An incremental improvement. *CoRR*, abs/1804.02767. Citado na página 1.

[Russakovsky et al., 2014] Russakovsky, O., Deng, J., e Su, H. (2014). Imagenet large scale visual recognition challenge. *CoRR*, abs/1409.0575. Citado na página 20.

[Sarwar et al., 2018] Sarwar, F., Griffin, A., Periasamy, P., Portas, K., e Law, J. (2018). Detecting and counting sheep with a convolutional neural network. In *2018 15th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS)*, páginas 1–6. Citado na página 1.

[Sasaki, 2007] Sasaki, Y. (2007). The truth of the f-measure. *Teach Tutor Mater*. Citado na página 21.

[Silva Oliveira Junior, 2019] Silva Oliveira Junior, A. (2019). Contagem e estimativa da massa de alevinos de pintado real utilizando técnicas de visão computacional e aprendizagem de máquina. Master's thesis, Universidade Federal de Mato Grosso do Sul, Campo Grande. Citado nas páginas xiii, 7, 18, e 19.

[Simonyan and Zisserman, 2014] Simonyan, K. e Zisserman, A. (2014). Very deep cnn for large-scale image recognition. *CoRR*, abs/1409.1556. Citado nas páginas 1 e 6.

[Simonyan and Zisserman, 2015] Simonyan, K. e Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. *CoRR*. Citado nas páginas 9 e 11.

[Sung et al., 2017] Sung, M., Yu, S., e Girdhar, Y. (2017). Vision based real-time fish detection using convolutional neural network. In *OCEANS 2017 - Aberdeen*, páginas 1–6. Citado na página 8.

[Tayara et al., 2018] Tayara, H., Gil Soo, K., e Chong, K. T. (2018). Vehicle detection and counting in high-resolution aerial images using convolutional regression neural network. *IEEE Access*, 6:2220–2230. Citado nas páginas 1 e 5.

[Tseng and Kuo, 2020] Tseng, C.-H. e Kuo, Y.-F. (2020). Detecting and counting harvested fish and identifying fish types in electronic monitoring system videos using deep convolutional neural networks. *ICES Journal of Marine Science*, 77(4):1367–1378. Citado na página 7.

[Wang and Lu, 2018] Wang, W. e Lu, Y. (2018). Analysis of the mean absolute error (mae) and the root mean square error (rmse) in assessing rounding model. *IOP Conference Series: Materials Science and Engineering*, 324:012049. Citado na página 20.

[Wang et al., 2019] Wang, Y., Luo, X., Ding, L., Fu, S., e Wei, X. (2019). Detection based visual tracking with convolutional neural network. *Knowledge-Based Systems*, 175:62 – 71. Citado na página 2.

[Zhang et al., 2015] Zhang, C., Li, H., Wang, X., e Yang, X. (2015). Cross-scene crowd counting via deep convolutional neural networks. páginas 833–841. Citado nas páginas 2, 5, e 6.

[Zhang et al., 2017] Zhang, L., Shi, M., e Chen, Q. (2017). Crowd counting via scale-adaptive convolutional neural network. *CoRR*, abs/1711.04433. Citado nas páginas 2 e 5.

[Zhao et al., 2017] Zhao, H., Shi, J., Qi, X., Wang, X., e Jia, J. (2017). Pyramid scene parsing network. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Citado nas páginas 1 e 5.